AYMARD THOMAS
ASLAN YUSUF
BESSABIS MALIK
BUT-SD-2A-VCOD-FI

Université Paris Cité

Rapport collecte automatisée de données web

SAE : Digitalisation des commerces parisiens

1) PRÉSENTATION GÉNÉRALE DU TRAVAIL ET DES OBJECTIFS :

Dans le cadre de cette SAE portant sur la digitalisation des commerces parisiens, l'objectif principal était d'enrichir la base de données fournie par l'APUR avec de nouvelles informations liées au numérique. Plus précisément, il s'agissait d'identifier, pour chaque commerce, ses coordonnées géographiques (latitude et longitude), l'existence éventuelle d'un site web, ainsi que la possibilité de livraison, notamment via des plateformes d'intermédiation comme UberEats ou Deliveroo. Ce travail s'inscrit dans une problématique actuelle, renforcée par la crise sanitaire du Covid-19, qui a accéléré la transformation digitale de nombreux commerces de proximité.

2) PRÉSENTATION DU CODE ET DES OUTILS UTILISÉS :

Le travail a été réalisé en Python à l'aide d'un notebook Jupyter (.ipynb), ce qui permet à la fois de structurer le code et de documenter les différentes étapes de l'analyse à l'aide de commentaires directement présents dans le fichier .ipynb. Les bibliothèques utilisées sont pandas pour la manipulation et le traitement des données, ainsi que d'autres bibliothèques vues en cours (requests, selenium, bs4 (BeautifulSoup), time & io).

Le code est organisé de manière progressive : importation des données initiales, sélection des variables utiles, puis enrichissement de la table avec les informations recherchées. Des affichages intermédiaires (par exemple sur les 20 premières lignes) ont été utilisés afin de vérifier le bon fonctionnement du code sans al[illegible] inutilement les calculs.

3) CHOIX MÉTHODOLOGIQUES EFFECTUÉS :

Plusieurs choix méthodologiques ont été faits afin de garantir la fiabilité et la lisibilité des résultats. Tout d'abord, pour les coordonnées GPS, les données ont été soit directement exploitées lorsqu'elles étaient disponibles, soit complétées à partir des informations d'adresse. Concernant la présence d'un site web, une attention particulière a été portée à la gestion des valeurs manquantes, en distinguant clairement les commerces ne disposant pas d'information de ceux n'ayant réellement pas de site.
Pour la possibilité de livraison, le choix a été fait de s'appuyer sur des indicateurs explicites présents dans les données ou sur des champs permettant d'identifier un partenariat avec des plateformes de livraison. Ces choix visent à rester cohérents avec les données disponibles tout en limitant les interprétations abusives.

4) DIFFICULTÉS RENCONTRÉES DURANT LE PROJET :

Plusieurs difficultés ont été rencontrées au cours du projet. La principale concerne la qualité et l'hétérogénéité des données, notamment la présence de nombreuses valeurs manquantes ou mal formatées. Cela a nécessité un travail de nettoyage et de vérification afin d'éviter les erreurs lors du traitement.
Une autre difficulté a été liée au temps de calcul et à l'affichage des résultats, la base contenant un grand nombre de commerces. Pour y remédier, des tests ont été effectués sur des sous-ensembles de données (par exemple les 20 premières lignes) avant d'appliquer les traitements à l'ensemble du fichier. Enfin, l'identification de la livraison n'est pas toujours triviale, certains commerces ne communiquant pas clairement sur ce service, ce qui limite parfois la précision de l'analyse.

5) BILAN :

Ce projet a permis de mettre en pratique de manière concrète les compétences de web scraping vues en cours, notamment en manipulation de données, structuration de code Python et analyse critique des données. Il met également en évidence les enjeux actuels de la digitalisation des commerces parisiens et les limites liées aux données disponibles.
Au-delà de l'aspect technique, cette SAE a permis de développer une démarche méthodologique rigoureuse, allant de la compréhension de la problématique jusqu'à l'interprétation des résultats, tout en tenant compte des contraintes réelles des données.