TP 2 - Modèle Linéaire

Thomas AYMARD - Mancef HENNICHE - Yusuf ASLAN - Malik BESSABIS

2026-04-06

Exercice sélection de variables

0. Ajuster le modèle de régression en incluant toutes les variables disponibles.

On cherche à prédire la note d'un joueur à partir de l'ensemble des variables numériques du jeu de données Premier League.

```
mod_complet <- lm(Note ~ ., data = pl_num)

cat("AIC du modèle complet :", AIC(mod_complet), "\n")
```

```
## AIC du modèle complet : 309.5403
```

```
cat("BIC du modèle complet :", BIC(mod_complet), "\n")
```

```
## BIC du modèle complet : 347.3477
```

Méthodes de recherche exhaustive :

1. Combien de modèles faut-il évaluer ?

2^8 = 256

Avec 8 variables explicatives, on doit comparer 256 modèles possibles. Ce nombre étant inférieur à 10 000, la recherche exhaustive est réalisable.

2. Appliquer toutes les méthodes exhaustives de sélection de variables et représenter le meilleur modèle par taille pour chaque critère.

```
p <- ncol(pl_num) - 1
choix_exhaustif <- regsubsets(Note ~ ., data = pl_num, nvmax = p, method = "exhaustive", nbest = 1)

par(mfrow = c(1, 3))
plot(choix_exhaustif, scale = "r2",    main = "R²")
plot(choix_exhaustif, scale = "adjr2", main = "R² ajusté")
plot(choix_exhaustif, scale = "bic",   main = "BIC")
```

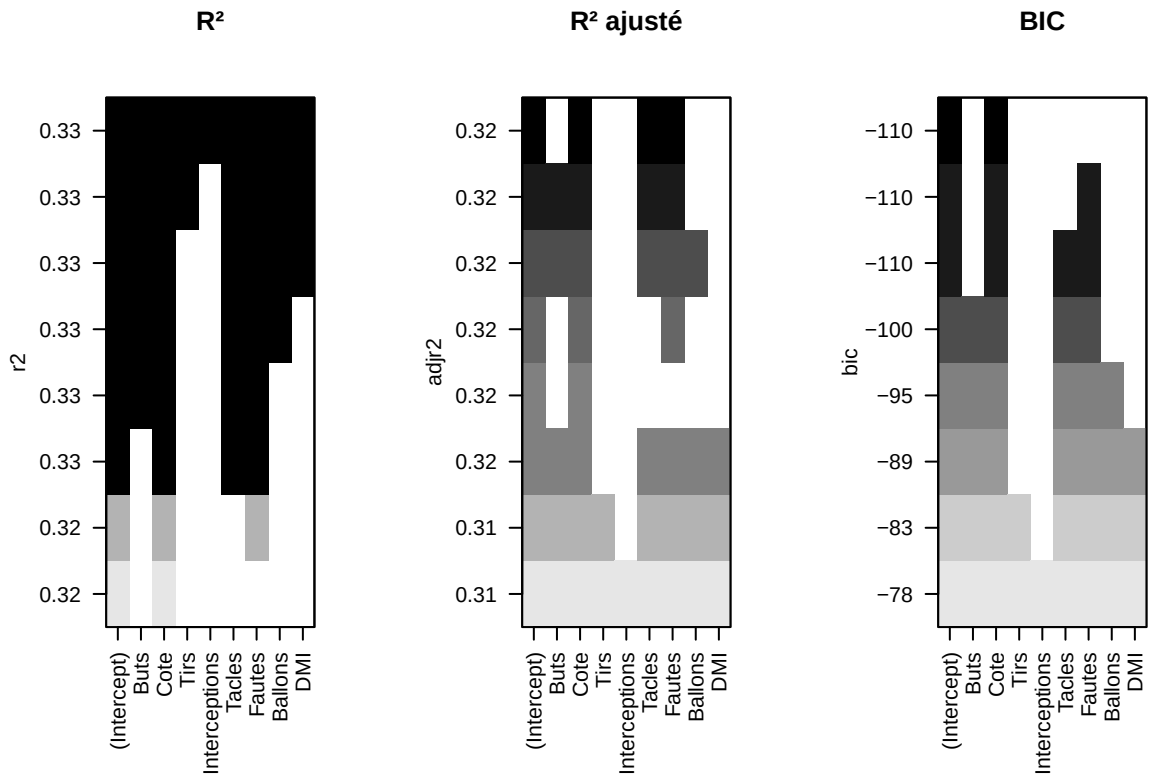


```r
par(mfrow = c(1, 1))
```

Sur les graphiques, chaque ligne correspond au meilleur modèle à k variables. Les cases noires indiquent les variables incluses dans le modèle. On lit que le meilleur modèle selon le BIC (valeur la moins négative, ici autour de -78) retient uniquement la variable Cote, ce qui correspond à un modèle simple avec peu de variables.

Méthodes de recherche pas à pas :

3. Sélection ascendante

On part du modèle vide (intercept seul) et on ajoute les variables une à une tant que le critère s'améliore.

- Avec le critère AIC

```r
mod_vide <- lm(Note ~ 1, data = pl_num)

mod_fwd_aic <- step(mod_vide, scope = formula(mod_complet),
                    direction = "forward", trace = TRUE, k = 2)
```

```
## Start:  AIC=-498.28
## Note ~ 1
##
##                 Df Sum of Sq    RSS     AIC
```

```
## + Cote           1   22.1165 47.060 -621.10
## + Tirs           1   11.2663 57.910 -553.88
## + Buts           1   11.0462 58.130 -552.65
## + Ballons        1    3.3511 65.826 -512.37
## + DMI            1    2.4745 66.702 -508.08
## + Fautes         1    1.5745 67.602 -503.74
## + Tacles         1    1.0299 68.147 -501.14
## + Interceptions  1    0.4823 68.694 -498.55
## <none>                       69.177 -498.28
##
## Step:  AIC=-621.1
## Note ~ Cote
##
##                 Df Sum of Sq    RSS     AIC
## <none>                       47.060 -621.10
## + Fautes         1  0.198786 46.861 -620.47
## + Buts           1  0.147848 46.912 -620.12
## + Tacles         1  0.108904 46.951 -619.85
## + Tirs           1  0.101556 46.959 -619.80
## + Interceptions  1  0.036747 47.024 -619.35
## + Ballons        1  0.010873 47.049 -619.17
## + DMI            1  0.006835 47.053 -619.14
```

```r
summary(mod_fwd_aic)$coefficients
```

```
##               Estimate  Std. Error  t value      Pr(>|t|)
## (Intercept) 4.57146676 0.048179745 94.88358 2.029479e-237
## Cote        0.04733995 0.003848303 12.30151  9.042415e-29
```

- Avec le critère BIC

```r
n <- nrow(pl_num)

mod_fwd_bic <- step(mod_vide, scope = formula(mod_complet),
                    direction = "forward", trace = FALSE, k = log(n))
summary(mod_fwd_bic)$coefficients
```

```
##               Estimate  Std. Error  t value      Pr(>|t|)
## (Intercept) 4.57146676 0.048179745 94.88358 2.029479e-237
## Cote        0.04733995 0.003848303 12.30151  9.042415e-29
```

4. Sélection descendante

On part du modèle complet et on retire les variables une à une tant que le critère s'améliore.

- Avec le critère AIC

```r
mod_bwd_aic <- step(mod_complet,
                    direction = "backward", trace = FALSE, k = 2)
summary(mod_bwd_aic)$coefficients
```

```
##                 Estimate  Std. Error   t value      Pr(>|t|)
## (Intercept)  4.568227920 0.054823494 83.326099 5.033759e-219
## Cote         0.049526049 0.004109512 12.051566  7.843885e-28
## Tacles       0.005556041 0.003103495  1.790253  7.435855e-02
## Fautes      -0.007307785 0.003736579 -1.955742  5.136542e-02
```

- Avec le critère BIC

```r
mod_bwd_bic <- step(mod_complet,
                    direction = "backward", trace = FALSE, k = log(n))
summary(mod_bwd_bic)$coefficients
```

```
##               Estimate  Std. Error  t value      Pr(>|t|)
## (Intercept) 4.57146676 0.048179745 94.88358 2.029479e-237
## Cote        0.04733995 0.003848303 12.30151  9.042415e-29
```

5. Méthode Stepwise

On autorise les ajouts et suppressions à chaque étape dans les deux sens.

- Avec le critère AIC

```r
mod_step_aic <- step(mod_vide, scope = formula(mod_complet),
                     direction = "both", trace = FALSE, k = 2)
summary(mod_step_aic)$coefficients
```

```
##               Estimate  Std. Error  t value      Pr(>|t|)
## (Intercept) 4.57146676 0.048179745 94.88358 2.029479e-237
## Cote        0.04733995 0.003848303 12.30151  9.042415e-29
```

- Avec le critère BIC

```r
mod_step_bic <- step(mod_vide, scope = formula(mod_complet),
                     direction = "both", trace = FALSE, k = log(n))
summary(mod_step_bic)$coefficients
```

```
##               Estimate  Std. Error  t value      Pr(>|t|)
## (Intercept) 4.57146676 0.048179745 94.88358 2.029479e-237
## Cote        0.04733995 0.003848303 12.30151  9.042415e-29
```

6. Comparer qualitativement les différents modèles. Sont-ils identiques ? Ont-ils beaucoup de variables en commun ? Lequel décide-t-on de garder et pourquoi ?

```r
cat("Forward  AIC :", (coef(mod_fwd_aic)),  "\n")
```

```
## Forward  AIC : 4.571467 0.04733995
```

```r
cat("Forward  BIC :", (coef(mod_fwd_bic)),  "\n")
```

```
## Forward  BIC : 4.571467 0.04733995
```

```r
cat("Backward AIC :", (coef(mod_bwd_aic)),  "\n")
```

```
## Backward AIC : 4.568228 0.04952605 0.005556041 -0.007307785
```

```r
cat("Backward BIC :", (coef(mod_bwd_bic)),  "\n")
```

```
## Backward BIC : 4.571467 0.04733995
```

```r
cat("Stepwise AIC :", (coef(mod_step_aic)), "\n")
```

```
## Stepwise AIC : 4.571467 0.04733995
```

```r
cat("Stepwise BIC :", (coef(mod_step_bic)), "\n")
```

```
## Stepwise BIC : 4.571467 0.04733995
```

```r
cat("\nBIC modèle complet          :", BIC(mod_complet),  "\n")
```

```
##
## BIC modèle complet          : 347.3477
```

```r
cat("BIC modèle retenu (step BIC):", BIC(mod_step_bic), "\n")
```

```
## BIC modèle retenu (step BIC): 311.7165
```

Toutes les méthodes avec le critère BIC (forward, backward, stepwise) aboutissent au même résultat : un modèle contenant uniquement la variable **Cote**. Avec le critère AIC, les résultats varient selon la méthode : forward et stepwise gardent uniquement **Cote**, tandis que backward retient aussi **Tacles et Fautes**.

On choisit de retenir le modèle sélectionné par le **critère BIC**, car il donne le modèle le plus simple : avec une seule variable (Cote), son BIC vaut **311.72**, contre **347.35** pour le modèle complet. Un BIC plus faible signifie un meilleur équilibre entre qualité d'ajustement et nombre de variables.

7. Vérifier les hypothèses du modèle linéaire pour le modèle complet et le modèle retenu.

```r
anova(mod_complet, mod_step_bic)
```

```
## Analysis of Variance Table
##
## Model 1: Note ~ Buts + Cote + Tirs + Interceptions + Tacles + Fautes +
##     Ballons + DMI
## Model 2: Note ~ Cote
##   Res.Df    RSS Df Sum of Sq      F Pr(>F)
## 1    315 46.363
## 2    322 47.060 -7  -0.69692 0.6764  0.692
```

```r
par(mfrow = c(2, 2), mar = c(4, 4, 2, 1))
plot(mod_step_bic)
```

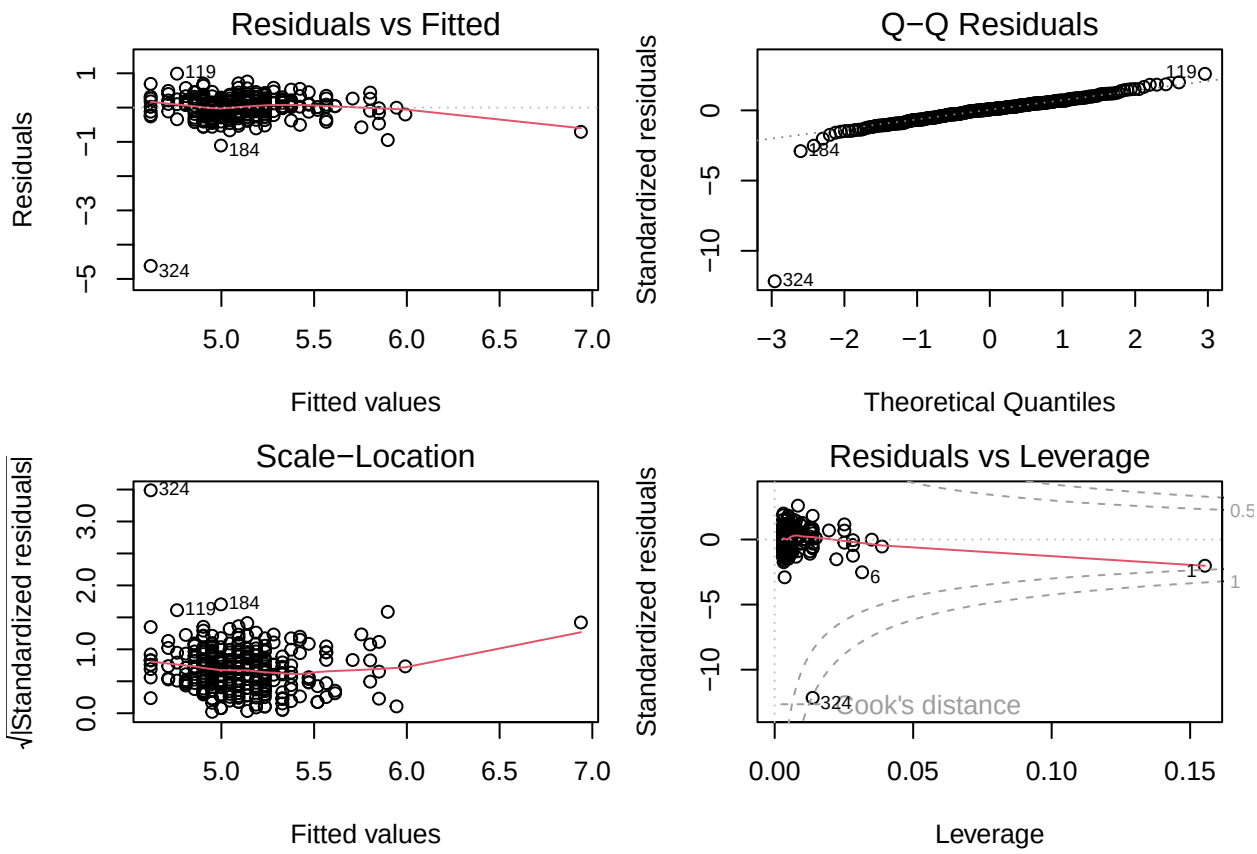


```r
par(mfrow = c(1, 1))
```

Le graphique *Residuals vs Fitted* montre que les résidus sont globalement centrés autour de zéro, mais l'observation 324 se détache nettement avec un résidu très négatif (environ -5), ce qui en fait un point aberrant potentiel. Le *Q-Q plot* révèle que la normalité des résidus est respectée pour la majorité des observations mais que les valeurs extrêmes s'écartent de la droite, notamment à cause de cette même observation. Le graphique *Scale-Location* indique une légère tendance à l'hétéroscédasticité (la dispersion augmente avec les valeurs ajustées). Enfin, le graphique *Residuals vs Leverage* confirme que l'observation 324 exerce une influence importante sur le modèle (distance de Cook élevée).

8. Représenter les prédictions en fonction des vraies valeurs et comparer les modèles.

On trace pour chaque modèle la droite de régression des prédictions en fonction des notes réelles, et on la compare à la droite idéale y = x (prédiction parfaite).

```r
cat("R² modèle complet :", summary(mod_complet)$r.squared, "\n")
```

```
## R² modèle complet : 0.329784
```

```r
cat("R² modèle BIC     :", summary(mod_step_bic)$r.squared, "\n")
```

```
## R² modèle BIC     : 0.3197095
```

Le modèle BIC ne prenant en compte que la variable côte est presque aussi performant que le modèle complet. On peut donc en déduire que la variable côte explique une grande partie de la note d'un joueur.

```r
pl_num$Pred_Complet <- fitted(mod_complet)
pl_num$Pred_Select  <- fitted(mod_step_bic)

ggplot(pl_num, aes(x = Note)) +
  geom_point(aes(y = Pred_Complet, color = "Modèle Complet"),           size = 2, alpha = 0.4) +
  geom_point(aes(y = Pred_Select,  color = "Modèle Sélectionné (BIC)"), size = 2, alpha = 0.4) +
  geom_smooth(aes(y = Pred_Complet, color = "Modèle Complet"),
              method = "lm", se = FALSE, linetype = "solid", linewidth = 1) +
  geom_smooth(aes(y = Pred_Select,  color = "Modèle Sélectionné (BIC)"),
              method = "lm", se = FALSE, linetype = "solid", linewidth = 1) +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed", color = "black", linewidth = 0.8) +
  labs(
    title   = "Prédictions vs Valeurs réelles",
    subtitle = "La droite pointillée représente une prédiction parfaite",
    x       = "Note réelle",
    y       = "Note prédite",
    color   = "Modèle"
  ) +
  scale_color_manual(values = c(
    "Modèle Complet"            = "gray50",
    "Modèle Sélectionné (BIC)"  = "steelblue"
  )) +
  theme_minimal()
```

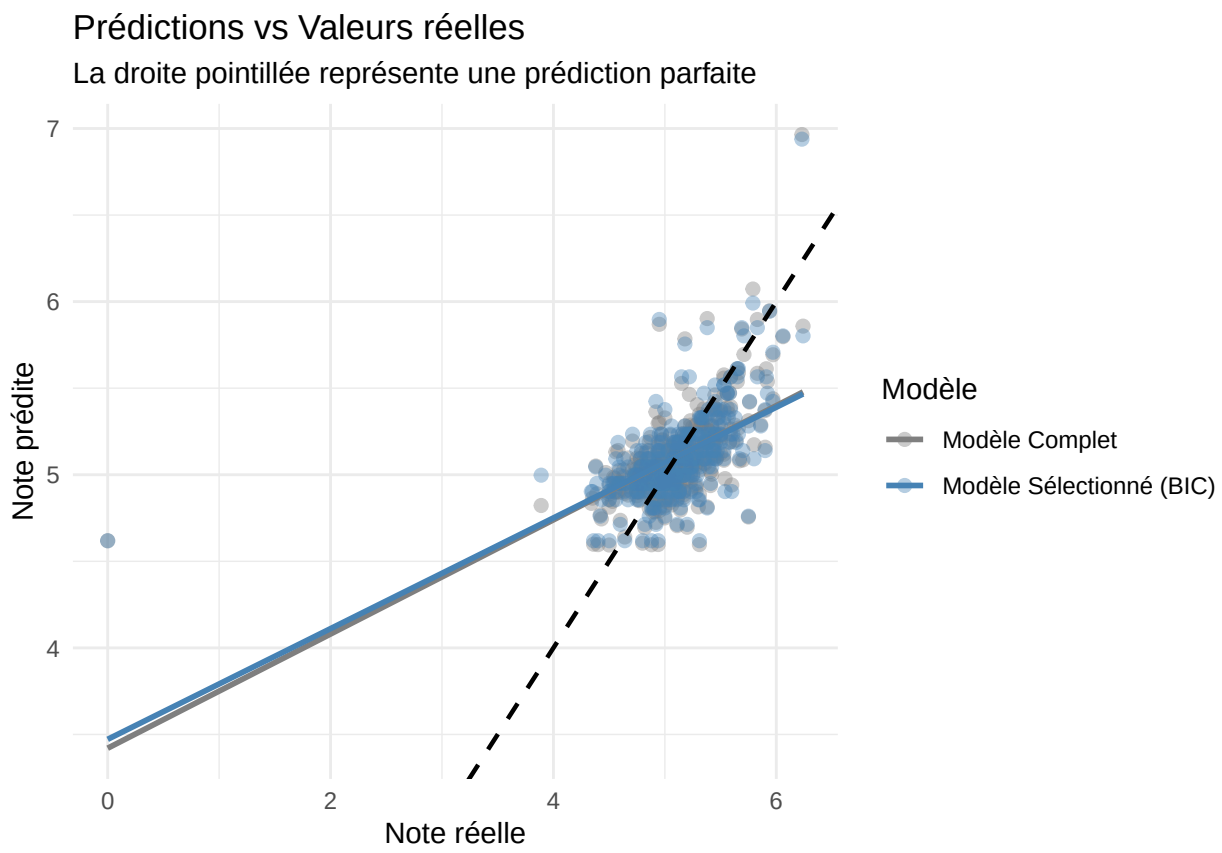

Les deux droites sont très proches l'une de l'autre, ce qui montre que le modèle avec une seule variable (Cote) prédit à peu près aussi bien que le modèle complet avec 8 variables. Les prédictions s'écartent de la droite idéale y = x surtout pour les notes très faibles ou très élevées, ce qui est une limite normale de ce type de modèle.

“‘